

Caso Práctico: Evaluación de Modelo de Clasificación en Banco General de Panamá

Contexto Empresarial

Empresa: Banco General S.A. (Panamá)

Sector: Servicios Financieros - Banca Retail y Corporativa

Desafío: Predecir la morosidad en créditos personales para implementar estrategias preventivas de gestión de riesgo crediticio

Problema de Negocio

El Banco General enfrenta un incremento en la tasa de morosidad (préstamos con más de 90 días de atraso) en su cartera de créditos personales, especialmente en el segmento de ingresos medios (\$1,500 - \$3,500 mensuales). Actualmente, el banco pierde aproximadamente **\$4.2 millones anuales** por créditos que entran en mora y eventualmente pasan a pérdida.

El equipo de Gestión de Riesgo necesita un modelo predictivo que identifique con anticipación (6 meses antes) qué clientes tienen alta probabilidad de caer en morosidad, permitiendo intervenciones tempranas.

Dataset y Variables

Tamaño de muestra: 15,000 créditos personales otorgados en los últimos 24 meses

Período de seguimiento: 18 meses desde el desembolso

Variables predictoras:

- Score crediticio interno (300-850)
- Relación cuota/ingreso mensual (%)
- Antigüedad laboral (meses)
- Número de productos bancarios activos
- Historial de pagos en últimos 12 meses
- Edad del cliente
- Monto del préstamo
- Plazo del crédito (meses)
- Sector económico de empleo
- Uso de línea de crédito (%)
- Promedio de saldo en cuenta corriente

Variable objetivo: Entró en morosidad (+90 días) - Sí/No

Distribución Real de la Cartera

- **Ciencia que cayeron en morosidad:** 2,250 (15%)
- **Ciencia que NO cayeron en morosidad:** 12,750 (85%)

Resultados del Modelo de Clasificación (XGBoost)

Matriz de Confusión sobre Conjunto de Validación (3,000 clientes)

	Predicción: NO Moroso	Predicción: Sí Moroso
Real: NO Moroso	2,380	170
Real: Sí Moroso	200	250

Desglose detallado:

- **Verdaderos Negativos (VN):** 2,380 clientes
- **Falsos Positivos (FP):** 170 clientes
- **Falsos Negativos (FN):** 200 clientes
- **Verdaderos Positivos (VP):** 250 clientes

Datos Financieros Complementarios

Costos y valores asociados:

- Pérdida promedio por crédito en mora severa (write-off): **\$8,500**
- Costo de intervención preventiva (reestructuración, asesoría financiera): **\$180 por cliente**
- Tasa de éxito de intervención preventiva: **65%** (evita la morosidad)
- Costo de gestión de cobranza reactiva: **\$450 por cliente**
- Costo reputacional por cliente que cae en mora: **\$120** (CSAT, NPS negativo)

PREGUNTAS

SECCIÓN A: Cálculo e Interpretación de Métricas (40 puntos)

Pregunta 1 (10 puntos):

Calcule la **Precisión (Precision)** del modelo y explique qué significa este resultado en el

contexto del Banco General. ¿Qué implicación tiene para los recursos del departamento de Riesgo Crediticio?

Pregunta 2 (10 puntos):

Calcule el **Recall (Sensibilidad)** del modelo. ¿Qué porcentaje de clientes morosos el banco está dejando de detectar? ¿Cuál es el impacto financiero estimado de estos Falsos Negativos?

Pregunta 3 (10 puntos):

Calcule el **F1-Score** del modelo. ¿Considera que este balance entre Precisión y Recall es adecuado para el caso de negocio del banco? Justifique su respuesta.

Pregunta 4 (10 puntos):

El modelo reporta un **AUC de 0.78**. Interprete este valor y evalúe si es suficientemente robusto para implementarse en producción. ¿Qué riesgos identifica?

SECCIÓN B: Análisis de Impacto de Negocio (30 puntos)

Pregunta 5 (15 puntos):

Calcule el **ROI financiero** de implementar el modelo durante un año, considerando:

- Total de clientes morosos proyectados en la cartera anual: 3,000 clientes
- Las métricas de rendimiento actuales del modelo (manteniendo proporciones)
- Los costos y tasas de éxito proporcionados
- Asuma que sin el modelo, el 95% de los casos morosos se gestionan reactivamente

Estructura sugerida: a) Costo actual sin modelo predictivo

b) Costo con modelo predictivo implementado

c) Ahorro neto y ROI porcentual

Pregunta 6 (15 puntos):

Analice los **trade-offs entre Falsos Positivos y Falsos Negativos** en este contexto:

- ¿Cuál tipo de error es más costoso para el banco? Cuantifique la diferencia
- ¿Qué otros impactos no financieros deben considerarse (experiencia del cliente, reputación)?
- ¿Debería el banco priorizar reducir FP o FN? Justifique

SECCIÓN C: Estrategia y Toma de Decisiones (30 puntos)

Pregunta 7 (10 puntos):

El equipo de Analytics propone **ajustar el umbral de decisión** del modelo de 0.5 a 0.35, lo que resultaría en:

- Recall aumenta a 70%

- Precisión disminuye a 52%

¿Recomienda este ajuste? Realice un análisis costo-beneficio comparativo y tome una decisión fundamentada.

Pregunta 8 (10 puntos):

Diseñe una **estrategia de segmentación** que aplique diferentes umbrales de decisión según perfiles de cliente. Considere al menos 3 segmentos basados en:

- Monto del crédito
- Score crediticio
- Relación cuota/ingreso
- Valor del cliente (cross-selling potencial)

Justifique por qué cada segmento requiere un tratamiento diferenciado.

Pregunta 9 (10 puntos):

Proponga un **plan de acción específico** para cada cuadrante de la matriz de confusión:

- a) **Verdaderos Positivos (VP):** ¿Qué intervenciones preventivas implementaría?
- b) **Falsos Positivos (FP):** ¿Cómo minimizar el impacto en la experiencia de estos clientes?
- c) **Falsos Negativos (FN):** ¿Qué mecanismos de alerta secundaria establecería?
- d) **Verdaderos Negativos (VN):** ¿Qué oportunidades de negocio identifica en este grupo?

SECCIÓN D: Implementación y Monitoreo (Bonus 10 puntos)

Pregunta 10 (10 puntos):

Diseñe un **dashboard ejecutivo** con los KPIs clave que el Gerente de Riesgo Crediticio debe monitorear mensualmente. Incluya:

- Métricas de rendimiento del modelo (mínimo 4)
- Indicadores de impacto financiero (mínimo 3)
- Señales de alerta para reentrenamiento del modelo
- Frecuencia de revisión recomendada para cada métrica

Presente su propuesta en formato de tabla estructurada con justificación de cada KPI seleccionado.

RECURSOS DE APOYO

Fórmulas Clave a Utilizar:

1. **Precisión:** $VP / (VP + FP)$
2. **Recall:** $VP / (VP + FN)$
3. **F1-Score:** $2 \times (\text{Precisión} \times \text{Recall}) / (\text{Precisión} + \text{Recall})$
4. **Accuracy:** $(VP + VN) / \text{Total}$
5. **Tasa de Falsos Positivos:** $FP / (FP + VN)$
6. **Valor Predictivo Negativo:** $VN / (VN + FN)$

Contexto Regulatorio Panameño:

- La Superintendencia de Bancos de Panamá (SBP) requiere que los bancos mantengan provisiones por créditos morosos
- El uso de modelos predictivos debe cumplir con el Acuerdo 4-2013 sobre Gestión de Riesgo de Crédito
- La protección de datos personales está regulada por la Ley 81 de 2019

Consideraciones Éticas:

- Evitar sesgos discriminatorios por género, edad o sector económico
- Transparencia con clientes sobre uso de modelos predictivos
- Derecho del cliente a explicación de decisiones automatizadas
- Balance entre prevención de pérdidas y acceso al crédito